


$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

$$\frac{\int_a^b \binom{n+m}{m} x^m (1-x)^n dx}{\int_0^1 \binom{n+m}{m} x^m (1-x)^n dx}$$

Introduction aux statistiques bayésiennes

Romain di Stasi, PhD

$$\frac{P(B|A_i) \cdot P(A_i)}{\sum_{j=1}^n P(B|A_j)P(A_j)}$$





◆ Pour comprendre ce que sont les **statistiques bayésiennes**, il faut comprendre :

→ Le **théorème de Bayes**

→ La **loi binomiale**

→ Une **vraisemblance et le maximum de vraisemblance**

Mais pas de panique, nous allons revenir sur ces aspects ici.

Le théorème de Bayes

- ◆ Contrairement aux statistiques fréquentistes, les statistiques bayésiennes ne suggèrent pas que la recherche part de zéro.

→ Tout part du mathématicien Britannique Thomas Bayes (1702-1761)

publié à titre posthume par Richard Price



$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Diagram illustrating Bayes' Theorem with color-coded labels and arrows:

- Blue label:** Probabilité de l'hypothèse A sachant les données B (points to $P(B|A)$)
- Green label:** Probabilité de l'hypothèse avant d'avoir vu les données → **probabilité a priori.** (points to $P(A)$)
- Red label:** Probabilité de l'hypothèse A sachant les données B (points to $P(A|B)$)
- Purple label:** Probabilité d'observer les données (toutes hypothèses confondues) → **évidence.** (points to $P(B)$)

Le théorème de Bayes - une brève histoire

Thomas Bayes montre ceci...


$$P(A | B) = P(A) \cdot P(B|A)$$

Cela revient au même que faire l'inverse :

$$P(B | A) = P(B) \cdot P(A|B)$$

Donc on obtient l'égalité suivante :

$$P(A) \cdot P(B|A) = P(B) \cdot P(A|B)$$



Le problème, c'est qu'écrit ainsi, on ne peut pas calculer la probabilité d'un événement en connaissant sa cause (l'autre probabilité). En effet, si l'on considère que B est la cause d'une partie de A, alors pour pouvoir estimer la probabilité de A étant donné B, il est indispensable de connaître la probabilité de B.

(Kruschke 2015, p. 99-118)

Le théorème de Bayes - une brève histoire

Thomas Bayes lui-même ne s'y est pas intéressé. C'est son ami Richard Price qui a publié ses travaux après sa mort.


Puis Pierre-Simon Laplace a découvert l'intérêt de l'égalité mise en évidence par Thomas Bayes qu'il a reformulée ainsi:



$$P(A) P(B|A) = P(B) \cdot P(A|B)$$

$$P(B|A) = \frac{P(B) \cdot P(A|B)}{P(A)}$$

Appelé probabilité
inverse



Pourquoi cela change toute notre approche ? Ici il faut revenir aux « vraisemblance » et à la manière dont les statistiques fréquentistes fonctionnent pour les différencier de l'approche bayésienne.

Fréquentiste

Vraisemblance des résultats x
dans le cadre d'une hypothèse H

$$P(x|H_0)$$

Quelle est la probabilité que j'aie un résultat x dans le cas où j'ai une hypothèse H . C'est « la vraisemblance du résultat ».

C'est tout ou rien, soit je conserve, soit je rejette H_0 .

Bayésiens


Plausibilité de l'hypothèse H
au vu des résultats x

$$P(H_0|x)$$


Quelle est la probabilité que mon hypothèse H soit vraie au vu des résultats obtenus x , c'est la plausibilité de mes hypothèses.

Elles permettent d'évaluer les niveaux de crédibilités de chaque hypothèse.


Le théorème de Bayes - une brève histoire




J'entends un bruit de grincement de parquet, c'est à cause de



H1: 2 %



H2: 32 %



H3 :66 %

Contrairement aux fréquentistes,
les bayésiens n'éliminent pas les
hypothèses : ils les évaluent.

Vraisemblance des résultats x
dans le cadre d'une hypothèse H

$$P(x|H_0)$$

Soit H_0

Si $P(x|H_0) < 1\%$

Alors on rejette H_0 ,
l'hypothèse doit être fausse

Si $P(x|H_0) \geq 1\%$

Alors on doit retenir H_0



Ronald Fisher

Ronald Fisher a rejeté le concept de probabilité inverse pour deux raisons:

(1) Trop **complexe à calculer**

(2) Trop **subjectif**

Ronald Fisher a rejeté le concept de probabilité inverse pour deux raisons:

(1) Trop complexe à calculer

$$P(H0 | x) = \frac{P(x|H0).P(H0)}{P(x|H0).P(H0) + P(x|H1).P(H1)}$$

$$P(H1 | x) = \frac{P(x|H1).P(H1)}{P(x|H0).P(H0) + P(x|H1).P(H1)}$$

Il faut calculer les vraisemblance
de chaque hypothèse...



Fréquentiste

(2) Trop subjective

$$P(H1 | x) = \frac{P(x|H1).P(H1)}{P(x)}$$

Prior

Il faut avoir un a priori sur l'hypothèse
(prédictions) avant même de l'avoir testée.

Le théorème de Bayes - une brève histoire

Ronald Fisher a rejeté le concept de probabilité inverse pour deux raisons:

(1) Trop complexe à calculer

Cette difficulté est avant tout **mathématique**, mais **le concept reste simple**.

Cela n'est plus un problème, maintenant que des ordinateurs peuvent réaliser ces calculs en quelques millièmes de seconde.


(2) Trop subjectif

Les statistiques fréquentistes ne le sont pas moins puisqu'elles reposent sur des choix.

Ronald Fisher a rejeté le concept de probabilité inverse pour deux raisons:

(2) Trop subjectif

Les statistiques fréquentistes ne sont pas moins subjectives, car elles reposent aussi sur des choix.



En fréquentiste, cette subjectivité est juste masquée artificiellement !

Les **statistiques bayésiennes** ont le mérite d'assumer cette subjectivité !

Ronald Fisher a rejeté le concept de probabilité inverse pour deux raisons:

(2) Trop subjectif

Mais... les statistiques bayésiennes sont parmi les plus proches de l'approche hypothético-déductive, puisqu'elles traduisent directement ce qu'on appelle la falsification de Popper.

En fréquentiste on part de H_0 est synonyme de pas d'effet et on ne peut jamais l'accepter.

En Bayésien, on ne se contente pas de tester une hypothèse nulle H_0 comme en fréquentiste, mais on compare explicitement plusieurs hypothèses ou modèles concurrents (H_0 et H_1) à l'aide du facteur bayésien (BF). Cette logique rend plus visible l'idée poppérienne de falsification, puisque chaque hypothèse est réellement mise à l'épreuve par rapport à une autre. Il est donc tout à fait possible de conclure qu'il y a davantage de soutien pour H_0 , plutôt que de la rejeter systématiquement.



Karl Popper

Le théorème de Bayes - une brève histoire

Pour rappel, la **falsification selon Popper** repose sur l'idée que, pour qu'une discipline soit considérée comme scientifique, ses hypothèses doivent être « falsifiables ». Il doit être possible de vérifier empiriquement si une hypothèse peut être réfutée ou non.

Il est impossible de montrer empiriquement que Dieu existe ou n'existe pas, c'est pourquoi la religion n'est pas une science.

L'exemple des moutons

~~Hypothèse 1 - tous les moutons sont blanc ou noir~~



Hypothèse 2 - presque tous les moutons sont blancs ou noirs mais il en existe des oranges



Le théorème de Bayes - une brève histoire

Pour reprendre l'exemple des moutons du cours précédent.

~~Hypothèse 1 - tous les moutons sont blanc ou noir~~



Hypothèse 2 - presque tous les moutons sont blancs ou noirs mais il en existe des oranges



Les statistiques Bayésiennes c'est exactement ça. Une évolution des connaissances.

~~Croyance A priori (Prior 1) - tous les moutons sont blanc ou noir.~~

Réfuté

Croyance A posteriori (Posterior) - presque tous les moutons sont blancs ou noirs mais il en existe des oranges.

Qui deviendra le Prior de l'étude suivante.

Statistiques Fréquentistes vs. bayésiennes, une illustration dans un jeu de rôle.




J'ai le D12, quelles sont les chances que j'aie chaque résultat possible ?

Il y a 12 faces numérotées donc 12 résultats possibles ?


$$\frac{100\%}{12} = 8,3\% \text{ pour chaque face.}$$

Si les faces ne sont pas équiprobables, on peut effectuer 10 000 lancers et établir une table de distribution empirique.



Cela est vrai pour n'importe quel type de dés.

Statistiques Fréquentistes vs. bayésiennes, une illustration dans un jeu de rôle.



L'objectif sera de répondre à la question suivante :

Le maître de jeu lance, il fait un 7. Est-ce que c'est un résultat extraordinaire ?

Le **statisticien fréquentiste** dira que cela dépend de ce qu'on appelle un résultat extraordinaire.

Il faudra définir un seuil pour différencier l'ordinaire de l'extraordinaire. Si on considère un seuil à 1 % (p_{seuil}) et que ma proba dans un D12 est de 8,3 %. Non ce n'est pas un résultat extraordinaire. Pas besoin de remettre en doute le maître de jeu.

Toutefois s'il tire 10 fois 7, là je pourrais me poser la question puisque là si j'ai 1/12 la probabilité de base qui est répétée 10 fois nous avons $\frac{1}{12^{10}} \approx 10^{-11}$ ce qui deçà de 1 % (p_{seuil}).

Statistiques Fréquentistes vs. bayésiennes, une illustration dans un jeu de rôle.



D4



D6



D8



D10



D12



D20

L'objectif sera de répondre à la question suivante :

Le maître de jeu lance, il fait un 7. Est-ce que c'est un résultat extraordinaire ?

Le statisticien bayésien se demandera : quel dé a été lancé ?

Ici, je ne cherche pas les chances d'obtenir ce résultat directement, mais davantage quel est le dé qui a été lancé.


Statistiques Fréquentistes vs. bayésiennes, une illustration dans un jeu de rôle.

L'objectif sera de répondre à la question suivante :

Le maître de jeu lance, il fait un 7. Est-ce que c'est un résultat extraordinaire ?

Le statisticien bayésien se demandera : quel dé a été lancé ?

Ici, je ne cherche pas les chances d'obtenir ce résultat directement, mais davantage quel est le dé qui a été lancé.




Statistiques Fréquentistes vs. bayésiennes, une illustration dans un jeu de rôle.

L'objectif sera de répondre à la question suivante :

Le maître de jeu lance, il fait un 7. Est-ce que c'est un résultat extraordinaire ?

Le statisticien bayésien se demandera : quel dé a été lancé ?

Ici, je ne cherche pas les chances d'obtenir ce résultat directement, mais davantage quel est le dé qui a été lancé.




D'accord, mais si nous devons parier, quel est le dé ayant la plus forte probabilité d'avoir été utilisé ?

L'approche fréquentiste considère que les chances sont égales, ce qui est une erreur...

Statistiques Fréquentistes vs. bayésiennes, une illustration dans un jeu de rôle.


Différents dés sont les hypothèses pour modéliser le résultat obtenu.




Un exemple d'intelligence artificielle et naturelle

Nous utilisons intuitivement cette méthode en permanence. Elle reflète probablement le mieux notre fonctionnement cérébral, qui repose sur des croyances (priors) constamment remises en question par nos observations.

Théorie du cerveau Bayésien






$$P(H3 | x) = \frac{P(x | H3) \cdot P(H3)}{P(x)}$$

Ma croyance a priori (prior)

Vraisemblance de mes résultats




Le $P(x)$ de cette équation est la réponse que les statisticiens fréquentistes cherchent, mais ils vont systématiquement s'arrêter là.

$$P(H3 | x) = \frac{P(x | H3) \cdot P(H3)}{P(x)}$$

$\sum$ Surfaces

Ici c'est...


$$2,062 + 1,66 + 1,39 + 0,83 = 5,942 \%$$




H1		0 %
H2		0 %
H3		34,70 %
H4		27,93 %
H5		23,39 %
H6		13,97 %

Puis il y aura une réactualisation des connaissances à chaque lancer. Si je relance un 7, on refait le calcul.

*Nouvelle croyance nouveau a priori
après le premier lancer (prior)*





- ◆ Un théorème que nous utilisons tous les jours sans le savoir.





→ La **question** que poserait le théorème de Bayes...

Quelle est la probabilité qu'il s'agisse d'un agent secret sachant qu'il a une tête de singe et une banane ?

→ Si on regroupait les indices « banane » et « tête de singe » en une seule catégorie ça donnerait...

$$P(S|A) = \frac{P(S \cap A)}{P(A)}$$





$$P(S|A) = \frac{P(S \cap A)}{P(A)} = \frac{P(S|A) \cdot P(S)}{P(A|S) \cdot P(S) + P(A|\bar{S}) \cdot P(\bar{S})}$$


Probabilité qu'il s'agisse d'un singe alors qu'il ressemble à James Bond

Mettons que nous ayons une chance sur dix de croiser un singe, puisque nous sommes à proximité d'un cirque ou d'un zoo. On a donc $P(S) = 0,1$, où S désigne l'événement "c'est un singe". Supposons également que, si c'est un singe, il y a 95% de chances d'observer cette image : $P(S|A) = 0,95$. $P(\bar{S})$ est la probabilité inverse de $P(S)$ donc $P(\bar{S}) = 1 - P(S)$. Enfin il faut supposer également que la probabilité d'avoir cette photo ne s'agissant pas d'un singe est de 1 % donc $P(A|\bar{S}) = 0,01$. Cela donne...

$$P(S|A) = \frac{0,95 \cdot 0,1}{0,95 \cdot 0,1 + 0,01 \cdot 0,9} = \frac{0,095}{0,095 + 0,009} = \frac{0,095}{0,104} \approx 0,913$$

Le théorème de Bayes est appliqué dans de nombreux domaines!

Un exemple d'intelligence artificielle et naturelle




Intelligence Artificiel
(e.g., réseau de neurones artificiels)

- ◆ Une machine apprend en réactualisant continuellement ses attentes qu'en statistiques bayésiennes ont appelle *a priori* (ou *prior*).
- ◆ Un humain fonctionne de la même manière : il a des attentes, et des observations qui vont plus ou moins être bouleversées. L'écart entre ses attentes et ses observations, s'il est mémorisé, constitue un apprentissage (voir article de Poli et al. 2024, ou Cook et al. 2011 pour une discussion détaillée sur les modèles de *reinforcement learning*).

Le théorème de Bayes est appliqué dans de nombreux domaines!

Un exemple l'Intelligence artificiel et naturelle

Ce qu'une IA fait, tout comme nous, c'est privilégier les réponses les plus étayées par des évidences, en fonction des hypothèses existantes, tout en évitant le surajustement (*overfitting*).



Un autre exemple...

- ◆ Dans un cas de test de dépistage d'une maladie
Tu es médecin et tu veux estimer la probabilité qu'un patient soit malade, sachant que son test est positif.

Nous avons 3 probabilités :

- Mal = « le patient a la maladie »
- $\overline{Mal}$ = « le patient n'a pas la maladie »
- Pos = le test est positif

Nous avons 3 données connues (*priors*) :

- $P(Mal)$ = prévalence de la maladie, 10% donc 0,1
- Spécificité du test $P(\overline{Pos} | \overline{Mal}) = 0,05$ puisqu'il y a 5% de chance d'un faux positif
- Sensibilité du test $P(Pos | Mal) = 0,99$ puisque le test détecte 99% des cas réel

(Adapté de Kruschke 2015, p. 104, table 5.4)

Un autre exemple...

- ◆ Dans un cas de test de dépistage d'une maladie

Quelle est la probabilité que le patient soit malade sachant qu'il a eu un test positif ?

$$P(A|B) = \frac{P(Pos|Mal).P(Mal)}{P(Pos|Mal).P(Mal) + P(Pos|\overline{Mal}).P(\overline{Mal})}$$
$$= \frac{0,99.0,1}{0,99.0,1+0,05.0,99} = \frac{0,099}{0,099+0,0495} = \frac{0,099}{0,1485} \approx 0,667 \approx 66,7 \%$$

Ainsi, même si le test est fiable à 99 % en sensibilité et à 95 % en spécificité, si la maladie est rare (1 %), alors un test positif ne signifie pas nécessairement que la personne est malade.

- ◆ Dans cet exemple de dépistage de la maladie, il faut bien comprendre la **notion de vraisemblance**...

Ici nous avons mesuré la probabilité que le test soit positif sachant que $P(A)$, la prévalence de la maladie est égale à 0,1...

La **vraisemblance** correspond à la probabilité d'observer certaines données *à supposer qu'une hypothèse soit vraie*. Nous l'avons déjà vue à travers l'exemple des dés. Par exemple, si je pense qu'il y a 40% de chances que le dé utilisé soit un D10, la vraisemblance est la probabilité que ce dé ait produit un 7 - autrement dit : *quelle est la compatibilité entre cette hypothèse et mon observation.*

(McElreath 2015, p. 32-33)

Dans le contexte du dépistage, la **vraisemblance** correspond à la probabilité que le test soit positif si la personne est réellement malade.



Ne pas confondre vraisemblance et *a posteriori*

Vraisemblance


$P(\text{test positif} | \text{malade})$

A posteriori

$P(\text{malade} | \text{test positif})$


Cas du dépistage

Terme	Représente quoi	Exemple dans le test
Croyance A priori (prior)	Ce que je pense avant de voir le test	$P(Mal) = 1\%$
Vraisemblance (Likelihood)	Probabilité d'observer le test positif si la personne est malade	$P(Pos)$
Croyance A posteriori (posterior)	Ce que je crois après avoir vu le test	$P(Mal) = 1$



Cas des dé


Terme	Représente quoi	Exemple dans le test
Croyance <i>A priori</i> (prior)	Ce que je pense avoir comme résultat	$P(\text{dé} = D10) = 40\%$
Vraisemblance (Likelihood)	Probabilité d'obtenir le résultat si l'hypothèse est vraie	$P(7)$
Croyance <i>A posteriori</i> (posterior)	Ce que je crois après avoir vu le test	$P(\text{Dé} = D10)$



- ◆ Le croyance *A posteriori* (ou *posterior*) représente la combinaison de l'information qui provient de l'observation des données et nos croyances *a priori* (*prior*)



Vraisemblance vs. Probabilité *a posteriori*

Rappel



Vraisemblance vs. Probabilité *a posteriori*

Rappel



La probabilité de nos données sachant notre ou nos hypothèses

Donc

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

◆ Afin de bien comprendre l'approche bayésienne et la vraisemblance il est assez intéressant de considérer une loi simple, **la loi binomiale**, pour plusieurs raisons.

→ Elle modélise des situations très courantes : succès/échec répétés.

→ Elle joue un rôle central en tant que **vraisemblance** dans l'approche bayésienne.

Puisque...

▶ Cette loi se base sur une probabilité *a priori* comme dans l'équation de Bayes

→ Elle est associée à une loi **conjuguée simple** : la loi bêta.

Elle est donc utilisable...

▶ Dans de nombreux cas qui nous intéressent en psychologie et neuroscience (e.g., différence de pourcentages).

- ◆ La loi binomiale consiste en la probabilité de constater une fréquence observée en fonction d'une fréquence attendue.

Cette dernière est binaire : cela peut se traduire par le fait d'avoir réussi ou non son exam, d'être malade ou non, *marquer à un panier de basket ou non, etc.*

- ◆ Admettons qu'un joueur de basket ait 60 % de chances de réussir un lancer franc.

- Quelle est la probabilité qu'il ne marque aucun point en deux essais ?
- Une fois sur les deux essais ?
- Deux fois sur les deux essais ?



© exemple tiré de [Primer](#)

- ◆ Admettons qu'un joueur de basket ait 60 % de chances de réussir un lancer franc.

→ Quelle est la probabilité qu'il ne marque aucun point en deux essais ?



© exemple tiré de [Primer](#)

- ◆ Admettons qu'un joueur de basket ait 60 % de chances de réussir un lancer franc.

→ Quelle est la probabilité qu'il ne marque aucun point en deux essais ?

$$p(\text{fail}, \text{fail}) = 1 - p(\text{success}) \times 1 - p(\text{success}) = 0,40 \times 0,40 \\ = 0,16 \text{ donc } 16\%$$



© exemple tiré de [Primer](#)

- ◆ Admettons qu'un joueur de basket ait 60 % de chances de réussir un lancer franc.

→ Quelle est la probabilité qu'il ne marque aucun point en deux essais ?

$$p(\text{fail}, \text{fail}) = 1 - p(\text{success}) \times 1 - p(\text{success}) = 0,40 \times 0,40 = 0,16 \text{ donc } 16\%$$

→ Une fois sur les deux essais ?



© exemple tiré de [Primer](#)

- ◆ Admettons qu'un joueur de basket ait 60 % de chances de réussir un lancer franc.

→ Quelle est la probabilité qu'il ne marque aucun point en deux essais ?

$$p(\text{fail}, \text{fail}) = 1 - p(\text{success}) \times 1 - p(\text{success}) = 0,40 \times 0,40 = 0,16 \text{ donc } 16\%$$

→ Une fois sur les deux essais ?

$$p(\text{success}, \text{fail}) + p(\text{fail}, \text{success}) = 0,60 \times 0,40 + 0,40 \times 0,60 = 0,48 \text{ donc } 48\%$$



© exemple tiré de [Primer](#)

- ◆ Admettons qu'un joueur de basket ait 60 % de chances de réussir un lancer franc.

→ Quelle est la probabilité qu'il ne marque aucun point en deux essais ?

$$p(\text{fail}, \text{fail}) = 1 - p(\text{success}) \times 1 - p(\text{success}) = 0,40 \times 0,40 = 0,16 \text{ donc } 16\%$$

→ Une fois sur les deux essais ?

$$p(\text{success}, \text{fail}) + p(\text{fail}, \text{success}) = 0,60 \times 0,40 + 0,40 \times 0,60 = 0,48 \text{ donc } 48\%$$

→ Deux fois sur les deux essais ?



© exemple tiré de [Primer](#)

- ◆ Admettons qu'un joueur de basket ait 60 % de chances de réussir un lancer franc.

→ Quelle est la probabilité qu'il ne marque aucun point en deux essais ?

$$p(\text{fail}, \text{fail}) = 1 - p(\text{success}) \times 1 - p(\text{success}) = 0,40 \times 0,40 = 0,16 \text{ donc } 16\%$$

→ Une fois sur les deux essais ?

$$p(\text{success}, \text{fail}) + p(\text{fail}, \text{success}) = 0,60 \times 0,40 + 0,40 \times 0,60 = 0,48 \text{ donc } 48\%$$

→ Deux fois sur les deux essais ?

$$p(\text{success}, \text{success}) = p(\text{success}) \times p(\text{success}) = 0,60 \times 0,60 = 0,36 \text{ donc } 36\%$$



© exemple tiré de [Primer](#)

- ◆ Cas d'une étude sur les déterminants des troubles du sommeil chez les enfants de 2 à 3 ans
 - Je sais que le pourcentage d'enfants atteint de trouble du sommeil dans la population d'étude est $p = 0,17$ ou 17%.
 - J'ai une taille d'échantillon de $n = 10$ et un nombre de personnes dans mon échantillon qui ont ce trouble de $k = 4$

La question que l'on se pose est : cet échantillon provient-il bien de la population étudiée ?

Donc, quelle est la probabilité d'observer 4 malades dans un échantillon de 10 sujets pris au hasard, sachant que la prévalence de la maladie est de 17 % ?

- (1) Soit cette probabilité est élevée, et dans ce cas, l'échantillon observé peut s'expliquer par une simple fluctuation aléatoire.
- (2) Soit elle est faible et l'échantillon ne représente pas la population.

Ce qu'on va chercher à faire c'est de comprendre par étapes :

- (1) Quelle est la probabilité d'observer k individus possédant une caractéristique donnée...
- (2) Dans un échantillon de n individus
- (3) Tirés dans une population où la proportion p de la caractéristique est connue.

Caractéristique = trouble du sommeil

k 4

Taille d'échantillon

n 10

Proportion de sujets porteurs de la
caractéristique de la population

p 0,17

Quelle est la probabilité de k succès au bout de
 n tentatives sachant que la probabilité p de
gagner à chacune des tentatives.

$$\Pr(k) = \frac{n!}{k! (n - k)!} p^k (1 - p)^{n-k}$$

$$\Pr(4) = \frac{10!}{4! (10 - 4)!} 0,17^4 (1 - 0,17)^{10-4} = 0,057 = 5,7 \%$$

Caractéristique = trouble du sommeil

Taille d'échantillon

Proportion de sujets porteurs de la
caractéristique de la population

k	0
n	10
p	0,17

Quelle est la probabilité de k succès au bout de
 n tentatives sachant que la probabilité p de
gagner à chacune des tentatives.

$$\Pr(k) = \frac{n!}{k! (n - k)!} p^k (1 - p)^{n-k}$$

$$\Pr(0) = \frac{10!}{0! (10 - 0)!} 0,17^0 (1 - 0,17)^{10-0} = 0,155 = 15,5 \%$$

$$\Pr(0) = \frac{10!}{0!(10-0)!} 0,17^0 (1-0,17)^{10-0} = 0,155 = 15,5 \%$$

$$\Pr(1) = \frac{10!}{1!(10-1)!} 0,17^1 (1-0,17)^{10-1} = 0,318 = 31,8 \%$$

$$\Pr(2) = \frac{10!}{2!(10-2)!} 0,17^2 (1-0,17)^{10-2} = 0,293 = 29,3 \%$$

$$\Pr(3) = \frac{10!}{3!(10-3)!} 0,17^3 (1-0,17)^{10-3} = 0,160 = 16,6 \%$$


$$\Pr(4) = \frac{10!}{4!(10-4)!} 0,17^4 (1-0,17)^{10-4} = 0,057 = 5,7 \%$$


$$\Pr(5) = \frac{10!}{5!(10-5)!} 0,17^5 (1-0,17)^{10-5} = 0,014 = 1,4 \%$$

⋮

$$\Pr(10) = \frac{10!}{10!(10-10)!} 0,17^{10} (1-0,17)^{10-10} = 0,00000002$$

= 0,000002 %







Ceci est une **fonction de densité**. La distribution théorique que vous êtes sensé obtenir si vous échantillonnez un certain nombre de participant. Elle est très importante car c'est elle qui va nous permettre de comprendre ce qui se passe statistiquement en traçant une droite de régression.

Vous avez sans doute toutes et tous entendu parler de la **régression linéaire**.

Ici ce serait une **régression logistique binomiale** puisque k ne peut prendre que deux modalités 0 ou 1.






En traçant cette droite, nous pouvons comprendre la relation qui existe entre deux variables, qu'il s'agisse de deux variables quantitatives ou d'une variable quantitative et d'une variable qualitative (par exemple : groupe contrôle vs groupe test)

C'est le même principe que la régression linéaire mais avec X pouvant prendre que deux valeurs 0 ou 1.



Pour **placer la droite** correctement vis-à-vis de cette fonction de densité il existe deux méthodes.

Les **moindres carrées** dans le cas d'un **régression linéaire classique**. Cela suppose que nous attendons à ce que les résidus de la pente (la fonction de densité) suivent une loi normale et la variance de ces derniers soit homogènes comme illustré ici.



Pour tous les autres cas nous appliquons le **maximum de vraisemblance**.

Appliquons maintenant le maximum de vraisemblance à la loi binomiale



Vraisemblance

La probabilité de nos données sachant notre ou nos hypothèses

Donc

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Loi Binomiale

- ◆ La vraisemblance est une fonction notée :

$$L(\theta) = P(\text{données} | \theta)$$

Probabilité d'observer les données si le paramètre du modèle est θ

- ◆ Le paramètre θ c'est le ou les paramètres inconnus que l'on cherche à estimer, il peut suivre un ensemble de loi de probabilité comme la loi normale, la loi de poisson (qui ont tous deux plusieurs paramètres) mais ici nous commencerons par loi de Binomiale qui n'en possède qu'un $\theta = p$, dont p est une probabilité fixe.
- ◆ Ensuite, nous avons ce que nous avons mesuré qui nous l'espérons suit la même loi, indépendante et identiquement distribuée notée $\{x_1, x_2, \dots, x_n\}$, elle suivront une loi de probabilité $f(x | \theta)$
- ◆ La fonction de vraisemblance est donc :


$$L(\theta) = \prod_{i=1}^n f(x_i | \theta)$$

Fonction de densité dans laquelle nous avons la probabilité d'observer x_i selon θ

Le produit de toutes les probabilités en supposant qu'elles soient indépendantes


- On cherche ensuite le maximum de vraisemblance (MLE)

L'idée ici est de trouver la valeur de θ qui rend les données les plus probables. Formellement ça donne:



Rappel

Fonction de densité



Exemple

- Supposons que je lance une pièce 10 fois, donc $n = 10$ et que j'observe $k = 7$ faces. Je veux estimer p , la probabilité de tomber sur face. La vraisemblance de la loi binomiale est :



$$L(p) = P(k \text{ face} | p) = \binom{10}{7} p^7 (1-p)^3$$

Puisque la loi binomial c'est


$$f(y|p) = \binom{n}{y} p^y (1-p)^{n-y}$$

- Le maximum de vraisemblance correspond au p qui maximise cette expression

$$\hat{p}^{MLE} = \frac{7}{10} = 0,7$$



$$L(\theta) = \prod_{i=1}^n f(x_i | \theta)$$



Cas particulier : en régression linéaire, la méthode des moindres carrés et le maximum de vraisemblance sont équivalents

- ◆ Qu'est-ce que la méthode des moindres carrés ?
Qui dit « moindres carrés » dit un retour aux régressions.
- ◆ Une question que l'on m'a souvent posée ces dernier temps est... y a-t-il des similitudes entre régression linéaire et statistiques bayésiennes.

En réalité, peu importe le type de statistiques que l'on fait, notre méthode repose toujours sur une formation linéaire de la fonction suivante :

$$y = ax + b$$

Si nous remontons à l'équation de la droite au lycée

et

$$y_i = \beta_0 + \beta_1 x_{i,1} + \dots + \beta_k x_{i,k} + \epsilon_i$$

Si nous revenons à quelque chose de plus récent


Valeur de y quand $x = 0$ autrement dit $\longrightarrow y = ax + \textcircled{b}$

$$y_i = \textcircled{\beta_0} + \textcircled{\beta_1} x_{i,1} + \dots + \textcircled{\beta_k} x_{i,k} + \textcircled{\epsilon_i}$$

Prédicteurs


L'erreur $\longrightarrow$ C'est-à-dire...
ou résidu


Effets (ou poids) de chaque prédicteur



L'objectif de toute régression est de bien positionner la droite, comme ici...

C'est là qu'il existe une différence entre statistiques bayésiennes et fréquentistes





Pour placer la droite lorsqu'on fait des analyses fréquentistes on utilise la **méthode des moindres carrés**. L'idée est de **minimiser la somme des carrés des écarts résiduels (SCER)** qui se formalise mathématiquement comme ceci :

$\hat{\mu}_y$ la moyenne
des prédiction y des
observations y_i

Le paramètre β représente la pente, il
peut y en avoir plusieurs dans les
régressions multiples.


$$SCER = \sum_i \hat{y}_i - (y_i)^2 = \sum_i \hat{\mu}_y - y_i + \beta(x_i - \hat{\mu}_x))^2$$

$\hat{y}_i$ représente la valeur
prédite pour une
observation i

Les observations y_i

Moyennes des x_i

Pour faire simple l'idée est que la somme des carrés des distances des points autour de sorte à ce que la somme de leurs distance aux carré soit la plus petite possible.



Maximum de vraisemblance dans une régression linéaire

◆ On estime pour une observation y qu'elle suit une régression linéaire tel que : $y \sim N(\beta_0 + \beta_1 x, \sigma)$

◆ La probabilité d'une observation de y est donc :

$$f(y|\beta_0, \beta_1, \sigma) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{y-\beta_0-\beta_1 x}{\sigma}\right)^2}$$

y est la variable aléatoire dépendante

x est la variable explicative (ou prédicteur)

β_0 est l'ordonnée à l'origine (intercept)


β_1 est le coefficient de régression (pente)

σ est l'écart type de l'erreur supposé normale (pente)

◆ Pour n observations indépendantes il faut considérer l'ensemble des probabilités conjointes en utilisant la formule de la fonction de densité $L(\theta)$ que nous avons vue tout à l'heure.

$$L(\beta_0, \beta_1, \sigma) = f(y_1, \dots, y_n | \beta_0, \beta_1, \sigma) = \underbrace{\prod_{i=1}^n}_{\text{observation}} \underbrace{\frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{y_i-\beta_0-\beta_1 x_i}{\sigma}\right)^2}}_{\text{paramètres}} = \underbrace{\prod_{i=1}^n f(x_i | \theta)}_{L(\theta)}$$

θ



Maximum de vraisemblance dans une régression linéaire


- ◆ Pour simplifier tous cela on fait souvent le logarithme de cette fonction

$$L(\beta_0, \beta_1, \sigma) = \prod_{i=1}^n \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{y_i - \beta_0 - \beta_1 x_i}{\sigma}\right)^2}$$

$$l(\beta_0, \beta_1, \sigma) = \sum_{i=1}^n \left(\log \left(\frac{1}{\sigma\sqrt{2\pi}} \right) - \frac{1}{2} \left(\frac{y_i - \beta_0 - \beta_1 x_i}{\sigma} \right)^2 \right)$$

$$l(\beta_0, \beta_1, \sigma) = n \log \left(\frac{1}{\sigma\sqrt{2\pi}} \right) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

Somme des
écarts au carré




Comme elle soustrait, plus cette somme est petite plus la vraisemblance sera grande

Maximum de vraisemblance dans une régression linéaire

- ◆ Pour simplifier tous cela on fait souvent le logarithme de cette fonction

$$l(\beta_0, \beta_1, \sigma) = n \log \left(\frac{1}{\sigma\sqrt{2\pi}} \right) - \frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2$$

Somme des
écarts aux carré



Comme elle soustrait, plus cette somme est petite plus la vraisemblance sera grande

En **régression linéaire classique**, lorsque les erreurs sont supposées normales, indépendantes et de variance constante, maximiser la vraisemblance revient exactement à minimiser la somme des carrés des résidus. C'est cette hypothèse de normalité qui fait apparaître la somme des carrés dans la log-vraisemblance. Ainsi, la méthode des moindres carrés est un cas particulier du maximum de vraisemblance. Le MLE apporte en plus une interprétation probabiliste et permet de généraliser l'approche à des modèles où l'erreur n'est pas normale (Poisson, binomiale, Gamma, etc.).


Maximum de vraisemblance dans une régression

- ◆ Concrètement que fait le maximum de vraisemblance par étapes :

Etape 1: Ce que l'on cherche

On a des points dispersés sur un graphique (valeurs de x et y) — par exemple, taille de l'enfant et nombre de mots qu'il connaît. On veut **trouver une droite qui colle le mieux** à ces points.

Etape 2: On essaye des droites



Certaines passent trop en dessous ou au-dessus des points, d'autres passent **pile au bon endroit** : c'est la meilleure droite.

Maximum de vraisemblance dans une régression

- ◆ Concrètement que fais le maximum de vraisemblance par étapes :

Etape 3: Une idée de "chance"

Pour chaque droite, on peut se demander : “À quel point cette droite rend mes données probables ?”

Autrement dit : si cette droite était la vraie, à quel point serait-ce normal d’observer ces points aussi proches (ou éloignés) ?

Au final la méthode du maximum de vraisemblance

C’est une méthode qui :


- Teste plein de droites différentes.
- Mesure pour chacune la "probabilité d’avoir obtenu ces données".
- Choisit la droite qui rend les données les plus probables.



◆ Quelle application ont ces deux méthodes : **Moindre carrée** vs. **Maximum de vraisemblance**.

Moindre carrée: est utilisé lorsque vous êtes dans le cadre d'une régression linéaire classique

- Ce qui veut dire que vos résidus suivent une loi normal centrée autour de la droite
- Qu'ils sont homoscedastique (i.e., homogénéité de la variances)
- Que votre Variable dépendante contiens au minimum 20 modalités possibles.



→ *Cumulative link models ('clm')* du package
« ordinal » (Christensen, 2023)

Puis *anova.clm* du package
« RVaideMémoire » (Herve 2011).

- ◆ Quelle application ont ces deux méthodes : **Moindre carrée** vs. **Maximum de vraisemblance**.

Maximum de vraisemblance : méthode couramment utilisée pour estimer les paramètres d'une régression linéaire généralisée (mais pas exclusivement). Elle consiste à ajuster les données en choisissant la loi de probabilité appropriée pour les résidus (e.g., binomiale, Poisson, Gamma, *etc.*).

Si l'on adopte une approche plus proche de la philosophie bayésienne, puisque le maximum de vraisemblance restreint l'espace dans lequel notre modèle va chercher les paramètres à l'image du *prior*. Par exemple, un temps de réaction de 1000 secondes n'est pas réaliste ; de même, une loi Gamma n'ira pas explorer des valeurs aberrantes de ce type.


L'approche bayésienne pousse cette logique encore plus loin : au lieu de chercher une seule "meilleure valeur" des paramètres, elle considère toutes les valeurs possibles et indique leur degré de plausibilité (en combinant les données et nos croyances préalables, appelées *priors*). Comme il est souvent trop compliqué de calculer cette distribution directement, on utilise des **simulations par chaînes de Markov (MCMC)** voir [ici](#) pour un exemple, qui permettent d'explorer progressivement l'espace des paramètres. On obtient ainsi non pas un seul chiffre, mais une distribution complète de possibilités.



Notion de Chaîne de Markov

- ◆ L'idée clé : le futur ne dépend pas du présent, mais du chemin qui l'y a mené.

Un exemple très simple la météo : on imagine un cas très simple de météo ou il n'y a que deux possibilités :



On dit qu'aujourd'hui il fait soleil. Demain selon notre modèle il y a donc 70 % de chance qu'il fasse beau et 30 % de chance qu'il pleuve. Et si aujourd'hui il pleut alors : il y a 60 % de chance qu'il continue de pleuvoir et 40 % de chance que le soleil revienne.

Ce modèle est un **Chaîne de Markov**:

- ◆ Tu passes d'un état (temps) à un autre
- ◆ Avec certaines probabilités de transition
- ◆ Et à chaque étape, seul l'état actuel compte pour prédire le suivant

Notion de Chaîne de Markov




Une chaîne de Markov, c'est comme un jeu

Imagine que tu jettes un dé ou que tu avances sur un jeu de plateau : Ton **prochain mouvement dépend de là où tu es maintenant**. Tu n'as pas besoin de te rappeler comment tu es arrivé là.


Une **chaîne de Markov**, c'est une suite d'étapes où chaque nouvelle étape **dépend uniquement de la précédente**, pas de toute l'histoire. En statistiques, on l'utilise pour **simuler** plein de scénarios possibles et **explorer** les valeurs probables d'un paramètre.

Notion de Chaîne de Markov

Va répéter ça x fois en resimulant les données et comparer nos données observées à nos données simulées pour voir quelle est l'hypothèse la plus vraisemblable.




Contrairement aux tests de permutations qui vont **redistribuer aléatoirement** les données dans les différentes conditions comme illustré ici avec les deux sacs de billes...




La chaîne de Markov ne modifie pas les données, elle applique différentes hypothèses et calcule leur vraisemblance.

Notion de Chaîne de Markov



Contrairement aux test de permutations qui vont **redistribuer aléatoirement** les données dans les différentes conditions comme illustré ici avec les deux sacs de billes...



La Chaîne de Markov ne change rien aux données, colles nos différentes hypothèses dessus et calcule sa vraisemblance.

Une chaîne de Markov propose une hypothèse (ex : un dé à 8 faces), puis envisage d'en tester une autre (ex : un dé à 10 faces), et **accepte ou rejette** la nouvelle hypothèse selon la vraisemblance.

- ◆ Je suis enquêteur et je veux savoir combien j'ai de personnes dopées chez mes 19 premiers coureurs.


→ Je sais que l'un des principaux symptômes de dopages est un taux d'hématocrite (i.e., quantité de globules rouges dans le sang) particulièrement élevé - 50%

- ◆ 8 sur les 19 cyclistes sont testés avec un taux élevé.

→ Donc 42 % de mon échantillon

- ◆ On sait que dans la population générale seul 13 % des sujets ont un hématocrite

→ L'idée est de calculer la probabilité qu'on ait $Prop_{observé} = 42\%$ alors que $Prop_{attendue} = 13\%$



Test du chi deux

Ou

p -value

Loi binomiale

- ◆ 8 sur les 19 cyclistes sont testés avec un taux élevé.

→ Donc 42 % de mon échantillon

- ◆ On sait que dans la population générale seul 13 % des sujets ont un hématoците

→ L'idée est de calculer la probabilité qu'on ait $Prop_{observé} = 42\%$ alors que $Prop_{attendue} = 13\%$


$$H_0 : Prop_{observe} = Prop_{attendu}$$

$$H_1 : Prop_{observe} > Prop_{attendu}$$

$$p = 0,002$$

- ◆ Mais ce n'est qu'un symptôme. Il y a d'autres raisons pouvant expliquer un taux élevé d'hématoците.

→ Un séjour à la montagne



- ◆ 8 sur les 19 cyclistes sont testés avec un taux élevé ($> 50\%$).
 - On trouve une étude qui montre que lorsque les individus consomment un produit X, 50% des participants ayant consommé ce produit dopant montent à 50%


- ◆ On peut donc réaliser un autre test en évaluant le pourcentage de personnes ayant un taux d'hématocrite supérieur à 50 % par rapport à une probabilité attendue de 50 % si 100 % des 19 coureurs avait consommé un produit dopant.

- Ici on aurait $Prop_{observé} = 42\%$ alors que $Prop_{attendue} = 50\%$

$$H_0 : Prop_{observe} = Prop_{attendu}$$

$$H_1 : Prop_{observe} > Prop_{attendu}$$

$$p = 0,32 \text{ ns}$$



© exemple tiré de [Thierry Ancelle](#)



Ici on est très ennuyé puisque on ne peut ni accepter H_0 ni la rejeter...

◆ Pour résumer on a deux études

- La première montre un résultat significatif mais n'est pas claire dans H1, on ne sait pas combien sont dopés, on a aucune probabilité de trouver un individu dopé dans la population
- La seconde ne permet pas de conclure...

◆ Si on part de l'hypothèse que la population de cycliste étudiée est une population dopée en utilisant une approche bayésienne basée sur la vraisemblance on aura...

$$V(H_{dopage}) = \Pr(D | H_{dopage}) = \Pr(8/19) \text{ si } P = 0,50$$

Puisque pour rappel la formule de la loi binomiale est :

$$\Pr(X = K) = \frac{n!}{k! (n - k)!} p^k (1 - P)^{n-k}$$

$$n = 19 \quad k = 8 \quad P = 0,5$$

$$V(H_{dopage}) = 0,144$$



Attention la vraisemblance n'est pas une probabilité et ne s'interprète sûrement pas comme la probabilité d'observer cet échantillon si mon hypothèse est vraie. Elle n'est pas suffisante seule.

- ◆ On peut faire l'hypothèse inverse en mesurant la vraisemblance des données selon l'hypothèse que mon échantillon appartienne à ma population normale.

$$V(H_{clean}) = \Pr(D | H_{clean}) = \Pr(8/19) \text{ si } P = 0,13$$

$$V(H_{clean}) = 0,00133$$

- ◆ On voit bien que nos deux vraisemblances

$$\begin{cases} V(H_{dopage}) = 0,144 \\ V(H_{clean}) = 0,00133 \end{cases} \longrightarrow \frac{V(H_{dopage}) = 0,144}{V(H_{clean}) = 0,00133} = 108,27 \approx 108$$

- ◆ Cela signifie que maintenant qu'on a recueilli les données la vraisemblance de l'hypothèse dopage (H_{dopage}) est 108 fois plus forte que celle d'une absence de dopage (H_{clean}).

→ C'est ce qu'on appelle **le Facteur de Bayes** : plus il est **élevé**, plus l'hypothèse est **vraisemblable**.

◆ Juste pour être sûr : si j'ai un facteur de Bayes de 2, que cela signifie-t-il ?

$$\frac{P(D | H_1)}{P(D | H_2)} = 2 \quad \longrightarrow \quad \text{Le résultat est deux fois plus vraisemblable sous } H_1$$



Partie Pratique utilisation du package brms

- ◆ Le langage privilégié pour les analyses bayésiennes est Stan. Heureusement, il est possible d'utiliser le package [brms](#), qui fait l'interface entre R et Stan (installé localement sur l'ordinateur), ce qui facilite grandement l'écriture et l'estimation des modèles.
- ◆ *Si brms facilite l'écriture de modèles bayésiens grâce à une syntaxe proche de lme4, il n'est pas le seul outil disponible : d'autres packages comme [Rstan](#) permettent également d'interfacer R avec Stan.*
- ◆ *brms présente l'avantage de bénéficier d'une large communauté active, notamment sur GitHub, et de nombreux tutoriels sont disponibles en ligne. Je vous recommande tout particulièrement celui proposé par [Our coding club](#) !*



```
data {  
  int<lower=0> N;  
  array[N] int<lower=0, upper=1> y;  
}  
  
parameters {  
  real<lower=0, upper=1> theta;  
}  
  
model {  
  // uniform prior on interval 0,1  
  theta ~ beta(1, 1);  
  y ~ bernoulli(theta);  
}
```

Example de Stan

Installation à faire sur son ordinateur !



R Version 4.4.2

IDE* recommandées



* Integrated Development Environment

Installation des packages

```
Install.packages('brms', dependencies = TRUE) # pour réaliser des modèles bayésiens  
Install.packages('emmeans') # pour les comparaisons post-hoc  
Install.packages('ggplot2') # pour produire les graphes
```

Charger les librairies

```
library(brms)  
library(emmeans)  
library(ggplot2)
```

Importer vos données dans R

```
setwd("../Data_for_bayes")  
Data Bayes = read.table(file = "yourdata.csv", header = TRUE, sep = ";", dec = ".", na.string = c("", "NAN"),  
stringsAsFactors = TRUE)
```

Modèle brms

```
Model_brm <- brms::brm(y~ x,  
data = data, family = poisson(), chains = 3,  
iter = 3000, warmup = 1000)  
  
# saveRDS(Model_brm, "Model_brm.RDS")  
# you can save the model as an RDS (Rdata) that way you don't need to run the model again if you come back to  
this code
```

- ▶ L'argument « **Chains** = 3 » veut dire « fais 3 chaînes de simulation différentes pour bien explorer toutes les possibilités »
- ▶ L'argument « **iter** = 3000, **warmup** = 1000 » veut dire « Simule 3000 itérations, dont 1000 pour l'échauffement ». Le modèle explore plein d'hypothèses, et :
 - 3000 = nombre total de simulations,
 - 1000 = les premières sont un “échauffement” pour que le modèle trouve une zone stable (elles ne sont pas gardées pour l'analyse)

Modèle brms

```
Model_brm <- brms::brm(y~ x,  
data = data, family = poisson(), chains = 3,  
iter = 3000, warmup = 1000)  
  
# saveRDS(Model_brm, "Model_brm.RDS")  
# you can save the model as an RDS (Rdata) that way you don't need to run the model again if you come back to  
this code
```


Ce code crée un **modèle bayésien** pour déterminer si la variable x prédit la variable y, qui représente un nombre d'événements. Nous utilisons ici une **distribution de Poisson**, qui ne prend en compte que des entiers naturels.

Modèle brms - notion de Chaîne de Markov

Rappel

- ◆ L'idée clé : le futur ne dépend pas du présent, mais du chemin qui l'y a mené.

Un exemple très simple la météo : on imagine un cas très simple de météo ou il n'y a que deux possibilités :



On dit qu'aujourd'hui il fait soleil. Demain selon notre modèle il y a donc 70 % de chance qu'il fasse beau et 30 % de chance qu'il pleuve. Et si aujourd'hui il pleut alors : il y a 60 % de chance qu'il continue de pleuvoir et 40 % de chance que le soleil revienne.

Ce modèle est un **Chaîne de Markov**:

- ◆ Tu passes d'un état (temps) à un autre
- ◆ Avec certaines probabilités de transition
- ◆ Et à chaque étape, seul l'état actuel compte pour prédire le suivant

Modèle brms - notion de Chaîne de Markov

Rappel



Une chaîne de Markov, c'est comme un jeu


Imagine que tu jettes un dé ou que tu avances sur un jeu de plateau : Ton **prochain mouvement dépend de là où tu es maintenant**. Tu n'as pas besoin de te rappeler comment tu es arrivé là.

Une **chaîne de Markov**, c'est une suite d'étapes où chaque nouvelle étape **dépend uniquement de la précédente**, pas de toute l'histoire. En statistiques, on l'utilise pour **simuler** plein de scénarios possibles et **explorer** les valeurs probables d'un paramètre.


Modèle brms - notion de Chaîne de Markov

Rappel

Va répéter ça x fois en resimulant les données et comparer nos données observées à nos données simulées pour voir quelle est l'hypothèse la plus vraisemblable.




Contrairement aux tests de permutations qui vont **redistribuer aléatoirement** les données dans les différentes conditions comme illustré ici avec les deux sacs de billes...




La chaîne de Markov ne modifie pas les données, elle applique différentes hypothèses et calcule leur vraisemblance.

Modèle brms - notion de Chaîne de Markov

Rappel



Contrairement aux test de permutations qui vont **redistribuer aléatoirement** les données dans les différentes conditions comme illustré ici avec les deux sacs de billes...



La Chaîne de Markov ne change rien aux données, colles nos différentes hypothèses dessus et calcule sa vraisemblance.

Une chaîne de Markov propose une hypothèse (ex : un dé à 8 faces), puis envisage d'en tester une autre (ex : un dé à 10 faces), et accepte ou rejette la nouvelle hypothèse selon la vraisemblance.

Modèle brms - notion de Chaîne de Markov






Attention une Chaîne de Markov doit absolument tester toutes les possibilités. Pour le tester rien de plus simple.

```
plot(Model_brm)
```

Les graphiques de type *Caterpillar* doivent être aussi détaillés que possible...

Plus ils le sont plus cela veut dire que votre chaîne de Markov explore l'ensemble des possibilités.



Modèle brms - notion de Chaîne de Markov




Attention une Chaîne de Markov doit absolument tester toutes les possibilités. Pour le tester rien de plus simple.

```
pp_check(Model_brm, ndraws = 10)
```

10 jeux de données simulées par les Chaînes de Markov dans le modèle (i.e., distribution théorique)

Distribution observée



Dans [Our Coding Club](#) ils suggèrent d'accepter cette différence, mais d'expérience étant donné le quasi bimodal observé j'aurais ajusté légèrement en faisant ce qu'on appelle des mixtures model.

Modèle brms - les priors

```
Model_brm <- brms::brm(y~ x,  
data = data, family = poisson(), chains = 3,  
iter = 3000, warmup = 1000)
```

↳ Modèle sans *prior* → Ce modèle ne prend pas en compte nos hypothèses préalables.

Dans la littérature, tu as vu précédemment que l'effet d'un phénomène était $d = 0,5$ et que son écart-type était de 2. La différence moyenne attendue est donc $\approx 0,5 \times 2 = 1$

↳ On s'attend donc à une différence d'environ 1

Les coefficients des variables explicatives se sont les effets fixes

```
prior = prior(normal(1, 1), class = "b")
```

Un écart type de 1 si tu es sûr que tu vas observer cette différence

Modèle brms - les priors

Les coefficient des variables explicatives se sont les effets fixes

```
prior(normal(1, 1), class = "b")
```

Dans $y_i = \beta_0 + \beta_1 x_{i,1} + \epsilon_i$

Ce n'est pas le seul *prior* que l'on peut mettre :

Tu peux également aider le modèle en lui disant la moyenne et l'écart-type que le groupe de référence à...


```
prior(normal(3, 1), class = "Intercept")
```

L'intercept correspond à la **moyenne du groupe de référence** (groupe A) et à β_0 dans l'équation de la droite. Puisqu'une **comparaison de moyenne correspond à un cas particulier de la régression linéaire**.

Modèle brms - un dernier *prior*, celle de l'erreur résiduel (ou résidues)

```
prior(normal(0, 2), class = "sigma")
```

↳ Cas classique de la régression (par défaut).



Mes priors

```
prior_model = prior(normal(0, 1), class = "b") + prior(normal(3, 1), class = "Intercept") + prior(normal(0, 2), class = "sigma")
```

Mon modèle

```
Model_brm <- brms::brm(y~ x,  
data = data, family = poisson(), chains = 3,  
prior = prior_model,  
iter = 3000, warmup = 1000)
```

L'extractions des statistiques

```
summary (Model_brm)
```


Mes post-hoc

```
emmeans(Model_brm, ~ pairwise~X)
```

Modèle Bayésien : régression linéaire mixte multiple

Mon modèle

```
Model_mixte_brm <- brm(y ~ x*z  
+ (1 | ID)  
, data = data  
, family = zero_inflated_beta()  
, prior = prior_model,  
, iter = 3000, warmup = 1000)
```



↳ Il est possible d'ajouter un facteur aléatoire en utilisant la même syntaxe que le package « lme4 »

L'extractions des statistiques

```
summary(Model_mixte_brm)
```

Les analyses post-hoc

```
emmeans(Model_mixte_brm, ~ pairwise~ z | x)
```

Summary

```
Family: poisson
Links: mu = log
Formula: pop ~ I(year - 1976)
Data: France (Number of observations: 70)
Draws: 3 chains, each with iter = 3000; warmup = 1000; thin = 1;
       total post-warmup draws = 6000
```

Population-Level Effects:


	Estimate	Est.Error	1-95% CI	u-95% CI	Rhat	Bulk_ESS	Tail_ESS
Intercept	8.70	0.00	8.70	8.71	1.00	1603	2216
IyearM1976	0.04	0.00	0.04	0.04	1.00	3479	3798

Draws were sampled using sampling(NUTS). For each parameter, Bulk_ESS and Tail_ESS are effective sample size measures, and Rhat is the potential scale reduction factor on split chains (at convergence, Rhat = 1).

< 1.01

> à 1000

> à 1000



L'intervalle de crédibilité (CrI) ne passe pas par zéro, ce qui indique que la différence est « crédible » ce qui se traduit en termes fréquentistes par « significative ».

Modèle Bayésien : régression linéaire mixte multiple

emmeans

Condition = Control:

Demo	emmean	lower.HPD	upper.HPD
------	--------	-----------	-----------

E1	-1.62233	-5.54	2.25
----	----------	-------	------

E2	-1.09361	-5.08	2.66
----	----------	-------	------

E3	-0.83152	-4.78	3.05
----	----------	-------	------

E4	-0.55457	-4.41	3.41
----	----------	-------	------

E5	-0.35519	-4.12	3.63
----	----------	-------	------

Condition = Test:

Demo	emmean	lower.HPD	upper.HPD
------	--------	-----------	-----------

E1	-0.23794	-4.03	3.72
----	----------	-------	------

E2	0.00363	-3.81	3.84
----	---------	-------	------

E3	-0.21479	-4.09	3.64
----	----------	-------	------

E4	-0.78565	-4.68	3.04
----	----------	-------	------

E5	-1.56607	-5.43	2.22
----	----------	-------	------

Point estimate displayed: median

HPD interval probability: 0.95

Modèle Bayésien : régression linéaire mixte multiple

emmeans

```
$contrasts
```

```
Condition = Control:
```

```
contrast estimate lower.HPD upper.HPD
```

E1 - E2	-0.533	-2.1561	0.990
E1 - E3	-0.793	-2.3210	0.767
E1 - E4	-1.079	-2.6245	0.456
E1 - E5	-1.283	-2.7779	0.266
E2 - E3	-0.264	-1.8297	1.278
E2 - E4	-0.539	-2.1010	1.031
E2 - E5	-0.746	-2.2344	0.852
E3 - E4	-0.283	-1.7713	1.305
E3 - E5	-0.491	-2.0657	1.036
E4 - E5	-0.203	-1.6892	1.361

Modèle Bayésien : régression linéaire mixte multiple

emmeans

Condition = Test:

contrast estimate lower.HPD upper.HPD

E1 - E2	-0.246	-1.7289	1.246
E1 - E3	-0.027	-1.5327	1.417
E1 - E4	0.543	-0.9075	2.020
E1 - E5	1.331	-0.1638	2.782
E2 - E3	0.219	-1.2040	1.709
E2 - E4	0.793	-0.6733	2.255
E2 - E5	1.568	0.0934	3.009
E3 - E4	0.574	-0.9363	1.971
E3 - E5	1.356	-0.0715	2.816
E4 - E5	0.773	-0.6938	2.191

Des modèles Bayésiens aux modèles multiverses

- ◆ Vous trouvez que les analyses Bayésiennes sont trop subjectives ?
- ◆ Vous pensez qu'il est trop difficile de caractériser des *priors* surtout quand la recherche est novatrice.
 - ↳ Rappelez-vous qu'une *p-value* sans analyse de puissance (par ex. avec GPower) est difficile à interpréter. Si vous avez trop peu d'individus par rapport à ce qu'indique GPower, vous augmentez vos chances de faux négatifs (ne pas détecter un effet qui existe). À l'inverse, si votre échantillon est trop grand, vous risquez de détecter comme significatifs de très petits effets, statistiquement réels mais peu pertinents d'un point de vue biologique.
 - ↳ L'analyse de puissance reste par définition assez subjective, puisqu'il est rare que votre condition expérimentale soit exactement identique à celle d'une étude précédente. On fait bien sûr de notre mieux pour s'en approcher, mais il subsiste toujours des différences.

Donc

La subjectivité des *priors* en bayésien n'est pas plus problématique que celle des analyses de puissance en fréquentiste.

- ◆ En outre, vous pouvez tester votre *prior*, via ce qu'on appelle des **tests de sensibilités**.

(Kallioinen et al., 2023; van de Schoot et al., 2021)

Le principe est de **tester plusieurs *priors*** dans une liste et voir lequel est **suffisamment informatif pour aider la convergence** de votre modèle sans pour autant trop fortement influencer vos « *Posterior* ».

Ma recommandation serait si votre hypothèse est assez forte de ne changer que votre paramètre d'incertitude, l'écart-type (*Standard Deviation, SD*). Comme dans l'exemple ci-dessous.

```
priors_test_sensitivity<- list(
  strong = prior(normal(0.11, 0.15), class = "b", coef = "Independent_variable1.L"),
  medium = prior(normal(0.11, 0.33), class = "b", coef = "Independent_variable1.L"),
  weak = prior(normal(0.11, 0.5), class = "b", coef = "Independent_variable1.L"),
  very_weak = prior(normal(0.11, 1), class = "b", coef = "Independent_variable1.L"),
  minimal = prior(normal(0.11, 1.67), class = "b", coef = "Independent_variable1.L"))
```

- ◆ En outre, vous pouvez tester votre *prior*, via ce qu'on appelle des tests de sensibilités.
(Kallioinen et al., 2023; van de Schoot et al., 2021)

Facteur aléatoire, l'individu.

```
model_strong_dependant_variable <- brm(dependant_variable ~ Independent_variable1*Independent_variable2
+ (1 | ID)
, data = data
, family = zero_inflated_poisson(link = "log", link_zi = "logit")
, prior = priors_test_sensitivity $strong
, iter = 2000, warmup = 1000
, chains = 2, cores = 2
, seed = 123
, save_pars = save_pars(all = TRUE))
```

Je diminue le nombre d'itérations et de warm-up puisque, comme je réalise cette analyse pour chaque *prior* du vecteur, il peut être long d'obtenir l'ensemble des résultats.

Ici je demande de chercher dans le vecteur que j'ai créé dans la diaporama suivante le *prior* « *strong* » ce qui correspond à :
« prior(normal(0.11, 0.15), class = "b", coef = "Condition.L") »

- ◆ En outre, vous pouvez tester votre *prior*, via ce qu'on appelle des tests de sensibilités.
(Kallioinen et al., 2023; van de Schoot et al., 2021)

↳ Il faut faire un modèle pour chaque *prior* créée dans cette liste.

```
priors_test_sensitivity<- list(  
strong = prior(normal(0.11, 0.15), class = "b", coef = "Independent_variable1.L"),  
medium = prior(normal(0.11, 0.33), class = "b", coef = "Independent_variable1.L"),  
weak = prior(normal(0.11, 0.5), class = "b", coef = "Independent_variable1.L"),  
very_weak = prior(normal(0.11, 1), class = "b", coef = "Independent_variable1.L"),  
minimal = prior(normal(0.11, 1.67), class = "b", coef = "Independent_variable1.L"))
```

Dans la diaporama précédente le modèle correspondait à ce *prior*.

- ◆ En outre, vous pouvez tester votre *prior*, via ce qu'on appelle des tests de sensibilités.

(Kallioinen et al., 2023; van de Schoot et al., 2021)

```
# Test the sensitivity of each of them
```

```
powerscale_sensitivity(model_strong_dependant_variable, variable = "b_Independent_variable1.L")  
powerscale_sensitivity(model_medium_dependant_variable, variable = "b_Independent_variable1.L")  
powerscale_sensitivity(model_weak_dependant_variable, variable = "b_Independent_variable1.L")  
powerscale_sensitivity(model_very_weak_dependant_variable, variable = "b_Independent_variable1.L")  
powerscale_sensitivity(model_minimal_dependant_variable, variable = "b_Independent_variable1.L")  
powerscale_sensitivity(model_flat_dependant_variable, variable = "b_Independent_variable1.L")
```

La fonction *powerscale_sensitivity* compare la valeur attendue d'après le *prior* seul à celle issue des données (*posterior*). En pratique, la différence entre les deux ne doit pas être trop importante : un écart de 20 à 30 % est généralement considéré comme acceptable.

- ◆ En outre, vous pouvez tester votre *prior*, via ce qu'on appelle des tests de sensibilités.
(Kallioinen et al., 2023; van de Schoot et al., 2021)

```
powerscale_sensitivity(model_strong_dependant_variable, variable = "b_Independent_variable1.L")
```

Likelihood selection: all data

# variable	prior	likelihood	diagnosis
# b_Independent_variable1	0.14	0.171	

Ici, le prior est acceptable puisque l'écart relatif entre le prior et le posterior (likelihood) est $|0.171 - 0.14| / 0.171 \approx 18 \%$, ce qui reste dans la tranche de 20-30 % mentionnée plus haut. Toutefois, il est recommandé de choisir un *prior* qui soit à la fois cohérent avec nos hypothèses (donc informatif) et qui n'influence pas excessivement le *posterior*. Il faut aussi impérativement que le prior soit en dessous du likelihood, voir Kallioinen et al. 2022 tableau)

- ◆ Vous pouvez visuellement voir ce que vos prior ont comme impact sur vos données avec les commandes suivantes : (Kallioinen et al., 2023; van de Schoot et al., 2021)

```
draws_strong_dependant_variable <- model_strong_GazeFre1s %>% spread_draws(b_Independent_variable1.L) %>%  
mutate(Prior = "Strong")
```

```
draws_medium_dependant_variable <- model_medium_GazeFre1s %>% spread_draws(b_Independent_variable1.L)  
%>% mutate(Prior = "Medium")
```

```
draws_weak_dependant_variable <- model_weak_GazeFre1s %>% spread_draws(b_Independent_variable1.L) %>%  
mutate(Prior = "Weak")
```

```
draws_very_weak_dependant_variable <- model_very_weak_GazeFre1s %>%  
spread_draws(b_Independent_variable1.L) %>% mutate(Prior = "Very Weak")
```

```
draws_minimal_dependant_variable <- model_minimal_GazeFre1s %>% spread_draws(b_Independent_variable1.L)  
%>% mutate(Prior = "Minimal")
```

```
draws_flat_dependant_variable <- model_flat_GazeFre1s %>% spread_draws(b_Independent_variable1.L) %>%  
mutate(Prior = "Flat")
```

- ◆ Vous pouvez visuellement voir ce que vos prior ont comme impact sur vos données avec les commandes suivantes : (Kallioinen et al., 2023; van de Schoot et al., 2021)

Puis

```
all_draws_prior <-  
bind_rows (draws_strong_dependant_variable,  
draws_medium_dependant_variable,  
draws_weak_dependant_variable,  
draws_very_weak_dependant_variable,  
draws_minimal_dependant_variable,  
draws_flat_dependant_variable )
```

- ◆ Vous pouvez visuellement voir ce que vos prior ont comme impact sur vos données avec les commandes suivantes : (Kallioinen et al., 2023; van de Schoot et al., 2021)

Enfin


```
prior_sensitivity_dependant_variable = ggplot(all_draws_dependant_variable, aes(x = b_
Independant_variable1.L, y = Prior, fill = Prior))
+ stat_halfeye(.width = c(.5, .8, .95))
+ geom_vline(xintercept = 0, linetype = "dashed")
+ labs(x = "Effect size ( $\beta$ )", y = NULL, title = "Sensitivity of Condition.L to Prior Choice")

+theme_minimal()
+theme(legend.position = "none")

prior_sensitivity_GazeFre1s
```

- ◆ Vous pouvez visuellement voir ce que vos prior ont comme impact sur vos données avec les commandes suivantes : (Kallioinen et al., 2023; van de Schoot et al., 2021)

Pour obtenir



Ici, vous voyez concrètement comment vos données se comportent en fonction du *prior* utilisé.

Le théorème de Bayes



Probabilité des
données B sachant
l'hypothèse A

$$P(A|B) = \frac{P(B|A) \cdot P(A)}{P(B)}$$

Probabilité de l'hypothèse A sachant les données B

Probabilité de l'hypothèse avant d'avoir vu les données → **probabilité a priori**.

Probabilité d'observer les données (toutes hypothèses confondues) → **évidence**.


$$P(A) = \frac{\text{orange hexagon}}{\text{box}}, \quad P(B|A) = \frac{\text{blue diamond}}{\text{orange hexagon}}$$

$$P(B) = \frac{\text{blue circle}}{\text{box}}, \quad P(A|B) = \frac{\text{blue diamond}}{\text{blue circle}}$$

$$P(A) \cdot P(B|A) = \frac{\text{orange hexagon}}{\text{box}} \times \frac{\text{blue diamond}}{\text{orange hexagon}} = \frac{\text{blue diamond}}{\text{box}}$$

$$P(B) \cdot P(A|B) = \frac{\text{blue circle}}{\text{box}} \times \frac{\text{blue diamond}}{\text{blue circle}} = \frac{\text{blue diamond}}{\text{box}}$$

$$= P(A) \cdot P(B|A), \text{ i.e.}$$



$$P(A|B) = \frac{P(A) \cdot P(B|A)}{P(B)}$$

$$P(B|A) = \frac{P(B) \cdot P(A|B)}{P(A)}$$

Comparaison de moyenne et régression linéaire



- ◆ Une comparaison de moyennes est un cas particulier de la régression linéaire

$$y_i = \beta_0 + \beta_1 x_{i,1} + \epsilon_i$$

y_i Score de l'individu

x_i 0 si l'individu est dans le groupe A (contrôle), $x_i = 1$ s'il est dans le groupe B (traitement)

β_0 Moyenne du groupe A

β_1 Différence de moyenne entre B et A

ϵ_i Bruit aléatoire

Un test t pour deux échantillons équivaut à une régression linéaire avec un prédicteur binaire.




Autre Exemple

- ◆ On souhaite estimer le **taux de germination** d'un lot de **semences** en faisant germer $n = 20$ semences dans des conditions similaires.
- ◆ Nous avons la **réponse** y , qui correspond au nombre de semences ayant germé avec succès.
- ◆ Nous savons que y suit une distribution binomiale où p est la probabilité de germination de la population:

$$f(y|p) = \binom{n}{y} p^y (1-p)^{n-y}$$

- ◆ $f(y|p)$ représente la distribution de y , conditionnelle à une valeur de p

Par exemple si on considère que j'ai une probabilité que mes plantes ont 20 % de chance de germer on va avoir $f(y|p) = 0,2$.



Il correspond à notre *prior* rappelez-vous l'exercice avec les dés




- ◆ L'estimé du maximum de vraisemblance pour p correspond à :

$$\hat{p} = \frac{y}{n}$$

- ◆ Dans notre exemple, avec $y = 6$ et $n = 20$ nous aurons :

$$\hat{p} = \frac{6}{20} = 0,3$$





- ◆ Subtilité importante - la fonction de densité des deux équations peut s'écrire de deux façons

Cas de figure 1 : On ne sait pas ce qu'il s'est passé **essai par essai**, mais on a le total. Tu sais que tu as 10 essais ($N = 10$) et il y a $y = 6$ succès.

Ici pas besoin de faire le produit de probabilités au lieu de ça on peut simplement écrire :

$$f(y|p) = \binom{n}{y} p^y (1 - p)^{n-y}$$

Cas de figure 2 : Tu observes chaque essai **séparément**.

Tu n'as pas le résultat final, il faut donc le calculer comme un produit :

$$f(y|p) = \prod_{i=1}^n p^{y_i} (1 - p)^{1-y_i}$$



Cas de figure 2 : Tu observes chaque essai séparément.

Tu n'as pas le résultat final, il faut donc le calculer comme un produit.


$$L(\theta) = \prod_{i=1}^n f(x_i | \theta)$$

$$L(p) = \prod_{i=1}^n \underbrace{p^{y_i} (1 - p)^{1-y_i}}_{f(x_i | \theta)}$$

(Note: The image shows a red bracket under the product term in the second equation, labeled $f(x_i | \theta)$. A red arrow points from the first equation's product term to the text below.)

Fonction de vraisemblance qui représente la probabilité d'observer y succès sur n si la proba de succès est p

Pour simplifier tous cela on fait souvent le logarithme de cette fonction



$$\log L(p) = \sum_{i=1}^n [y_i \log(p) + (1 - y_i) \log(1 - p)]$$

Comme précédemment l'objectif est de maximiser cette fonction en trouvant la valeur p qui rend **les données les plus probables**.